



Séries Temporelles

Analyse de séries temporelles

Wilfried Heyse

wilfried.heyse@polytech-lille.fr

Polytech Lille IS^{IA}2A5

Organisation :

10h CM : W. Heyse

14h TP : W. Heyse

Évaluation :

Contrôle Continu : $4 \times \sim 15$ minutes

1 feuille recto de notes manuscrites autorisée.

Examen Écrit : 1h30

1 feuille recto-verso de notes manuscrites autorisée.

Examen Pratique : 1h30

Cours et Anciens TP's autorisés, pas d'accès à internet.

Langage utilisé : R

Cours Moodle : IS2A5 Séries Temporelles (🔒 gdyesc)


Introduction

Définition 1.1

Une *série temporelle* à temps discret est une suite $(x_t)_{1 \leq t \leq T}$ d'observations d'un même phénomène à différents instants indicés par t .


Remarque :

Ici les observations sont réalisées sur un même sujet statistique, elles ne sont donc pas indépendantes entre elles.




Objectif : Apprendre à **modéliser** et **prédire** les séries temporelles.

Historiquement, les séries temporelles sont envisagées sous la forme de signaux qui sont décomposés pour les décrire et les prédire.




Objectif : Apprendre à **modéliser** et **prédire** les séries temporelles.


Historiquement, les séries temporelles sont envisagées sous la forme de signaux qui sont décomposés pour les décrire et les prédire.



Tendance T_t





Saisonnalité S_t




Résidu R_t

Objectif : Apprendre à **modéliser** et **prédire** les séries temporelles.


Historiquement, les séries temporelles sont envisagées sous la forme de signaux qui sont décomposés pour les décrire et les prédire.



Tendance T_t



Saisonnalité S_t



Résidu R_t

Analyse Descriptive

La première étape de l'analyse d'une série temporelle est l'analyse descriptive. Celle-ci permet de visualiser les caractéristiques principales de la série et d'orienter son analyse statistique.

Objectif : Décrire les caractéristiques principales d'une série temporelle :

- Identifier des indices de tendance,
- Identifier des indices de saisonnalité,
- Identifier le type de modèle.

Définition 2.1

On appelle **processus stochastique** une famille de variables aléatoires indexées sur le temps $(X_t)_{t \in T}$ définies sur un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$. Chaque observation sur la durée T est une réalisation du processus aléatoire.

Remarque :

Les processus stochastiques sont des modèles probabilistes qui permettent de décrire les séries temporelles.


Remarque :

Les observations $x_1, x_2, \dots, x_T$ ne constituent pas un échantillon i.i.d., puisqu'elles sont issues de variables $X_1, \dots, X_T$ qui sont *a priori* liées entre elles par la structure temporelle du processus et ne suivent pas nécessairement la même loi.

Remarque :

Le pas de temps des observations de la série temporelle $(X_t)_{t \in T}$ n'a pas besoin d'être défini et n'aura aucun impact sur les analyses statistiques ou la modélisation (or interprétation des résultats). On fait cependant l'hypothèse que les **observations sont régulièrement espacées** dans le temps.

La première étape lors de l'analyse d'une série temporelle est de la représenter graphiquement. La représentation la plus classique est le graphe des observations en fonction du temps, le *chronogramme*.



Ce graphe donne des indices de tendance, de saisonnalité, de type de série et d'anomalies diverses.

Définition 2.2

La **tendance**, notée T_t , est une évolution générale de la série temporelle sur une longue période.

La tendance peut s'écrire comme une combinaison linéaire de m fonctions du temps définies a priori, de la forme :

$$T_t = \sum_{i=1}^p \beta_i f_i(t)$$


Elle peut être croissante, décroissante ou stable et de forme linéaire, quadratique, exponentielle, etc.

Remarque :


La tendance peut aussi être **stochastique**. Ce cas ne sera pas abordé dans ce cours.

Exemple :

Les figures 1a et 1b illustrent des tendances linéaires et quadratiques.



(a) Tendence linéaire




(b) Tendence quadratique


Figure – Exemples de séries à tendances

Définition 2.3

La **saisonnalité**, notée S_t , est une variation cyclique de la série temporelle qui se répète à intervalles réguliers. On note P la période de la saisonnalité, elle vérifie donc : $S_{t+P} = S_t$.



(a) Saisonnalité seule




(b) Série


Figure – Exemples de séries à tendance linéaire et a saisonnalité

Définition 2.4

La **saisonnalité**, notée S_t , est une variation cyclique de la série temporelle qui se répète à intervalles réguliers. On note P la période de la saisonnalité, elle vérifie donc : $S_{t+P} = S_t$.



(a) Saisonnalité seule



(b) Série

Figure – Exemples de séries à tendance quadratique et a saisonnalité

Il existe deux grands types de modèles de séries temporelles : les modèles additifs et les modèles multiplicatifs.

Définition 2.5

Un modèle **additif** est de la forme :

$$X_t = T_t + S_t + R_t,$$

où T_t est une tendance déterministe, S_t est une saisonnalité déterministe et R_t est un résidu stochastique centré.


Proposition 2.6

Les modèles additifs vérifient :

$$\mathbb{E}(X_t) = T_t + S_t \text{ et } \text{Var}(X_t) = \text{Var}(R_t)$$

Les modèles additifs sont reconnaissables par la présence de tendances et de saisonnalités qui s'ajoutent à un résidu. Les composantes sont souvent identifiables graphiquement.

Exemple :



Définition 2.7

Un modèle **multiplicatif** est de la forme :

$$X_t = T_t \times S_t \times R_t,$$

où T_t est une tendance déterministe, S_t est une saisonnalité déterministe et R_t est un résidu stochastique.

Proposition 2.8


Les modèles multiplicatifs vérifient :

$$\mathbb{E}(X_t) = T_t \times S_t \text{ et } \text{Var}(X_t) = T_t^2 \times S_t^2 \times \text{Var}(R_t)$$

La variance de ces processus dépend donc du temps, de la tendance et de la saisonnalité.


Les modèles multiplicatif sont reconnaissables par la présence de tendances et de saisonnalités qui se multiplient à un résidu ce qui se traduit par des courbes incluses dans un entonnoir.

Exemple :




Les modèles multiplicatif sont reconnaissables par la présence de tendances et de saisonnalités qui se multiplient à un résidu ce qui se traduit par des courbes incluses dans un entonnoir.

Exemple :



Les modèles multiplicatif sont reconnaissables par la présence de tendances et de saisonnalités qui se multiplient à un résidu ce qui se traduit par des courbes incluses dans un entonnoir.

Exemple :



Les modèles multiplicatifs peuvent en réalité être transformés en modèles additifs en prenant le logarithme des observations :

$$X_t = T_t \times S_t \times R_t$$


$$\log(X_t) = \log(T_t) + \log(S_t) + \log(R_t)$$

Les modèles multiplicatifs ne font donc pas l'objet d'une étude spécifique dans ce cours.


Remarque :

On pourra aussi envisager des modèles mixtes, qui combinent les deux types de modèles. Ceux-ci ne seront pas abordés dans ce cours.

Le *lag plot* est un outil graphique qui permet de visualiser la corrélation entre une observation et une observation décalée dans le temps. Il permet de mettre en évidence la présence de corrélation temporelle dans la série.




(a) Série




(b) Lag-plot

Le *month plot* est un outil qui, connaissant la période de la saisonnalité d'une série, permet de représenter ensemble les observations de chaque moment de la période pour mettre en évidence la saisonnalité.



Le chronogramme saisonnier est un outil qui, connaissant la période de la saisonnalité d'une série, permet de superposer les observations de chaque saison pour mettre en évidence la tendance et la saisonnalité.



Analyse statistique

L'analyse statistique des séries temporelles permet de quantifier les phénomènes observés et de tester leur significativité.

Objectif : Tester la présence de tendance et de saisonnalité dans une série temporelle.

Méthode : Analyse de la variance.

L'analyse de la variance peut permettre d'affiner les résultats qui auraient pu être déduits des représentations graphiques et donner des éléments statistiques sur la présence de saisonnalité.

Étant donné une série temporelle X_t , sans tendance, ayant une composante saisonnière de période P , observée N fois. En notant $X_{i,j}$ la j -ème observation de la série à l'instant i -ème période, on peut écrire la série comme : $X_{i,j} = S_j + R_{i,j}$ où S_j est la saisonnalité et $R_{i,j}$ le résidu. On suppose que les résidus sont i.i.d. de loi $\mathcal{N}(0, \sigma^2)$.

Calcul de la variance : La somme totale des carrés de la série est donnée par :

$$S_T = \sum_{i=1}^N \sum_{j=1}^P (x_{i,j} - \bar{x})^2$$

où $\bar{X}$ est la moyenne de la série : $\bar{X} = \frac{1}{N \times P} \sum_{i=1}^N \sum_{j=1}^P x_{ij}$. On

note $x_{i.} = \sum_{j=1}^P x_{i,j}$ et $x_{.j} = \sum_{i=1}^N x_{i,j}$, on définit alors :

$S_{\text{inter}} = P \sum_{i=1}^N (x_{i.} - \bar{x})^2$ la somme des carrés inter-saisonnalité et

$S_{\text{intra}} = N \sum_{j=1}^P (x_{.j} - \bar{x})^2$ la somme des carrés intra-saisonnalité.

La somme des carrés résiduelle est notée :

$$S_R = \sum_{i=1}^N \sum_{j=1}^P (x_{ij} - x_{i.} - x_{.j} + \bar{x})^2$$

On a alors la relation : $S_T = S_{\text{inter}} + S_{\text{intra}} + S_R$.

Test de la saisonnalité :

Hypothèse nulle : H_0 : Absence de saisonnalité ($S_{\text{intra}} = 0$).

On peut alors tester la présence de saisonnalité en comparant la variance intra-saisonnalité à la variance résiduelle. On définit le test de Fisher :

$$F = \frac{S_{\text{intra}}/(P-1)}{S_R/((N-1) \times (P-1))} \hookrightarrow \mathcal{F}_{P-1, (N-1) \times (P-1)}$$

Test de la tendance :

Hypothèse nulle : H_0 : Absence de tendance ($S_{\text{inter}} = 0$).

On peut alors tester la présence de tendance en comparant la variance inter-saisonnalité à la variance résiduelle. On définit le test de Fisher :

$$F = \frac{S_{\text{inter}}/(N-1)}{S_R/((N-1) \times (P-1))} \hookrightarrow \mathcal{F}_{N-1, (N-1) \times (P-1)}$$

L'analyse de la corrélation permet de quantifier la relation entre les observations d'une série temporelle et de tester la présence de corrélation temporelle.

Objectif : Tester la présence de corrélation temporelle dans une série temporelle.

Méthode : Analyse de l'auto-corrélation.

Définition 3.1 Auto-covariance

On définit l'auto-covariance de la série temporelle X_t d'ordre (ou de retard ou lag) k :

$$\sigma(k) = \text{Cov}(X_t, X_{t-k}) = \mathbb{E}[(X_t - \mathbb{E}(X_t)) \times (X_{t-k} - \mathbb{E}(X_{t-k}))]$$

et sa version empirique :

$$\hat{\sigma}(k) = \frac{1}{N-k} \sum_{t=k}^N (x_t - \bar{x}) \times (x_{t-k} - \bar{x})$$

L'auto-covariance renseigne sur la dépendance statistique entre deux variables espacées de k temps.

Définition 3.2 Auto-corrélation

On définit l'auto-corrélation de la série temporelle X_t d'ordre (ou de retard) k :

$$\rho(k) = \frac{\text{Cov}(X_t, X_{t-k})}{\sqrt{\text{Var}(X_t) \times \text{Var}(X_{t-k})}}$$

et sa version empirique :

$$\hat{\rho}(k) = \frac{\hat{\sigma}(k)}{\hat{\sigma}(0)}$$


Pour trouver la période d'une série temporelle :

- **Calculer l'auto-corrélation pour différents retards** : On calcule l'auto-corrélation $\rho(k)$ pour différents retards k .
- **Tracer l'auto-corrélogramme** : On trace un graphique avec les valeurs de k sur l'axe des abscisses et les valeurs de $\rho(k)$ sur l'axe des ordonnées.
- **Identifier les pics de corrélation** : Les pics de corrélation indiquent les retards pour lesquels la série temporelle est fortement corrélée avec elle-même. La distance entre deux pics successifs correspond à la période de la série temporelle.

Proposition 3.3

Soit X_t une série temporelle dont la composante saisonnière est non-nulle de période P et la tendance et le résidu sont nuls. La forme de l'auto-corrélogramme est alors sinusoïdale :


$$\hat{\rho}(k) \xrightarrow{T \rightarrow +\infty} \cos\left(\frac{2\pi k}{P}\right)$$



Proposition 3.4

Soit X_t une série temporelle dont la tendance est polynomiale et la composante saisonnière et le résidu sont nuls. La forme de l'auto-corrélogramme est alors :

$$\hat{\rho}(k) \xrightarrow{T \rightarrow +\infty} 1$$



On peut alors tester la présence de corrélation temporelle en comparant la fonction d'auto-corrélation à 0.

Test de l'auto-corrélation :

Hypothèse nulle : $H_0 : \rho(k) = 0$.

Sous H_0 , l'intervalle de confiance est donné par :

$$\hat{\rho}(k) \in \left[-t^{\frac{\alpha}{2}} \frac{1}{\sqrt{T}}; t^{\frac{\alpha}{2}} \frac{1}{\sqrt{T}} \right]$$

Cet intervalle est calculé pour un niveau de confiance de $1 - \alpha$ et $t^{\frac{\alpha}{2}}$ est le quantile de la loi de normale. Il est par défaut tracé sur les auto-corrélogrammes. Il est possible d'avoir de l'ordre de K (le nombre de retards testés) $\times \alpha$ faux rejets.

Test du porte manteau (Box-Pierce) :

Hypothèse nulle : $H_0 : \rho(1) = \rho(2) = \dots = \rho(K) = 0$.

Hypothèse alternative : $H_1 : \exists k \in \{1, \dots, K\}, \rho(k) \neq 0$.

Sous H_0 , la statistique de test :

$$Q = T \sum_{k=1}^K \hat{\rho}(k)^2 \hookrightarrow \chi_K^2$$

avec T le nombre d'observations et K le nombre de retards testés.

Le test du porte manteau permet de tester la corrélation globale de la série temporelle. Il est souvent utilisé pour tester la présence de saisonnalité.

Test du porte manteau (Ljung-Box) :

Hypothèse nulle : $H_0 : \rho(1) = \rho(2) = \dots = \rho(K) = 0$.

Sous H_0 , la statistique de test :

$$Q = T(T+2) \sum_{k=1}^K \frac{\hat{\rho}(k)^2}{T-K} \hookrightarrow \chi_K^2$$

avec T le nombre d'observations et K le nombre de retards testés.

Le test du porte manteau permet de tester la corrélation globale de la série temporelle. Il est souvent utilisé pour tester la présence de saisonnalité.

Étude de cas sous R

On se concentre sur l'étude de la série temporelle des températures mensuelles moyennes à Lille enregistrées entre 1951 et 2021.

```
> Data_Temp_Lille <- read.csv("Cours/Graphes/SH_MTN459343001.csv")  
> head(Data_Temp_Lille)
```

	YYYYMM	VALEUR	Q_HOM
1	195101	3.0	1
2	195102	2.1	1
3	195103	2.3	1
4	195104	3.7	1
5	195105	8.3	1
6	195106	10.3	1

La première étape consiste à vérifier le bon import des données et à les mettre en forme.

```
> Data_Temp_Lille$YYYYMM <- paste0(
  substr(Data_Temp_Lille$YYYYMM, start=1, stop=4), "-",
  substr(Data_Temp_Lille$YYYYMM, start=5, stop=6), "-01")
> Data_Temp_Lille$YYYYMM <- as.Date(Data_Temp_Lille$YYYYMM,
  tryFormats = "%Y-%m-%d")
> head(Data_Temp_Lille)
```

	YYYYMM	VALEUR	Q_HOM
1	1951-01-01	3.0	1
2	1951-02-01	2.1	1
3	1951-03-01	2.3	1
4	1951-04-01	3.7	1
5	1951-05-01	8.3	1
6	1951-06-01	10.3	1

1 Qu'est-ce qu'un objet ts ?

Un objet de classe ts en R est une structure spécialisée pour stocker et manipuler des séries temporelles. Il permet de représenter des données indexées par le temps (dates, heures, années, etc.) et facilite l'application de méthodes d'analyse spécifiques (graphiques, autocorrélation, tests statistiques, etc.).

2 Caractéristiques principales :


- **data** : Un vecteur numérique représentant les observations de la série.
- **frequency** : Le nombre d'observations par unité de temps (ex. : frequency = 12 pour des données mensuelles).
- **start** : Définies par les arguments start et end (ex. : start = c(2020, 1) pour janvier 2020).

```
> ts_Temp_Lille <- ts(Data_Temp_Lille$VALEUR,  
  start = c(1951,1), frequency = 12)
```


```
> head(ts_Temp_Lille, 36)
```

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
1951	3.0	2.1	2.3	3.7	8.3	10.3	12.1	13.1	12.2	4.9	6.2	2.2
1952	0.5	0.1	4.1	6.3	9.3	10.5	13.0	13.4	7.8	5.8	1.8	0.1
1953	-0.9	0.6	1.7	5.7	9.4	11.8	13.3	12.9	10.3	8.3	4.0	3.8


```
> plot(ts_Temp_Lille)
```



```
> lag.plot(ts_Temp_Lille, lags = 24, layout = c(4,6))
```



```
> acf(ts_Temp_Lille, lags = 36)
```



```
> Data_Temp_Lille$YYYY<-format(Data_Temp_Lille$YYYYMM, format="%")
> Data_Temp_Lille$MM<-format(Data_Temp_Lille$YYYYMM, format="%m")
>
```

```
> anova(lm(VALEUR~YYYY,data=Data_Temp_Lille))
Analysis of Variance Table
```

Response: VALEUR

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
YYYY	71	546.5	7.6979	0.314	1
Residuals	792	19414.2	24.5129		

```
> anova(lm(VALEUR~MM,data=Data_Temp_Lille))
Analysis of Variance Table
```

Response: VALEUR

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
MM	11	17687.6	1607.97	602.69	< 2.2e-16 ***
Residuals	852	2273.1	2.67		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> Box.test(ts_Temp_Lille, lag = 12, type = "Box-Pierce")
```

Box-Pierce test

data: ts_Temp_Lille

X-squared = 3989.9, df = 12, p-value < 2.2e-16

```
> Box.test(ts_Temp_Lille, lag = 12, type = "Ljung-Box")
```

Box-Ljung test

data: ts_Temp_Lille

X-squared = 4031.8, df = 12, p-value < 2.2e-16